

친환경 섬유 소재 개발을 위한 최적 물성 예측 알고리즘에 관한 연구

임주희¹ · 양진호¹ · 조강연¹ · 노상도^{1*} · 손현식² · 정우창³ · 심승범³

¹성균관대학교 산업공학과 / ²다이텍연구원 섬유소재솔루션사업단 /

³한국섬유개발연구원 산연혁신지원실

A Study on the Optimal Property Prediction Algorithm for Development of Eco-friendly Fiber Material

Joo Hee Lym¹ · Jinho Yang¹ · Kang Yeon Cho¹ · Sang Do Noh¹ · Hyun Sik Son² ·

Wu Chang Jung³ · Seung Bum Sim³

¹Department of Industrial Engineering, Sungkyunkwan University

²Textile Material Solution Group, Korea Dyeing and Finishing Technology Institute

³Industrial & Research Innovation Support Group, Korea Textile Development Institute

Due to various environmental issues such as global warming, eco-friendly technology becomes more significant attention in manufacturing industries. In textile industry, a large amount of chemicals substances and energy can cause serious environmental pollution, so that it is necessary to develop and use eco-friendly fiber material to keep our environment clean. Extraction of optimal process conditions and prediction of the product quality before production starts are the critical steps to reduce the waste and defect rate in developing biodegradable eco-friendly materials. This paper proposes an AI-based algorithm that predicts the optimal process conditions and parameters of the spinning process based on manufacturing data. The developed algorithm is consisted of various machine learning models, and the performance of the model is verified by performance indicator evaluation of actual production processes.

Keywords: Artificial Intelligence, Big Data Analytics, Deep Learning, Machine Learning, Spinning Process

1. 서 론

인구 증가와 급격한 산업의 발전으로 인한 자원고갈 및 탄소 사용량 증가는 지구온난화를 비롯한 다양한 환경문제를 발생시키고 있다. 이러한 문제점을 해결하기 위해 제조기업들에 대한 친환경 소재 생산으로의 전환 요구가 확대되고 있으며, 이는 특정 제조 산업에 국한된 것이 아니라 전체 제조 산업에서의 중요한 변화 패러다임이다(Yun, 2020). 섬유산업은 에너

지 소비 감축이나 온실가스 배출 감축 노력을 등한시하면서 에너지 효율성이 낮아지고 있으며, 여러 종류의 화학 약품 사용과 용수 재사용의 어려움, 에너지의 대량 사용 등 환경 오염을 유발하고 있다. 따라서 섬유산업에서도 최근 환경을 보존하기 위한 노력과 더불어 친환경 섬유에 대한 관심과 기술개발이 지속되고 있다(Korea Chemical Fibers Association, 2013). 또한, 글로벌 환경 규제에 의한 친환경 소재에 대한 수요 증가에 따라 수요기업 요구에 대응 가능한 친환경 섬유 소재와 공

본 논문은 산업통상자원부와 한국산업기술진흥원의 소재부품기술기반혁신사업의 지원을 받아 수행된 연구입니다(과제번호: P0022335).

* 연락저자 : 노상도 교수, 16419 경기도 수원시 장안구 서부로 2066 성균관대학교 제2공학관 27420B, Tel : 031-290-7603, Fax : 031-290-7610,

E-mail : sdnoh@skku.edu

2022년 5월 13일 접수; 2022년 6월 29일, 2022년 8월 19일, 2022년 9월 16일, 수정본 접수; 2022년 9월 22일 게재 확정.

정 기술의 추진이 필요한 상황이다. 섬유는 대부분 고분자로 이루어져 있으며, 다양한 조건에서 일련의 공정을 통하여 요구되는 물성에 맞는 섬유를 형성시키기 위해 방사 공정을 거쳐 섬유의 형태로 변환된다(KOREA Institute of Convergence Textile, 2000). 일반적으로 고분자 재료는 기존의 잘 알려진 재료보다 값싸고 다양한 용도로 사용되고 있지만, 수명이 다하여 처분할 때 자연적으로 완전히 분해되기 위해서는 종류에 따라서 수백 년이 걸리는 단점을 가지고 있다. 이러한 문제를 해결하기 위해서 빠른 시간 내에 자연적으로 분해되는 친환경 고분자 재료에 관한 연구가 활발히 진행되고 있다. 친환경 고분자는 생분해성 고분자라고도 하며, 이를 이용하여 제조된 섬유를 생분해성 섬유라고 한다(Cheric.org, 2001). 전술한 글로벌 친환경 추세에 발맞춰 국내에서도 생분해성 섬유 소재에 대한 경쟁력 확보가 요구되며, 고강도 생분해성 섬유 개발은 필수적이다. 또한, 새로운 친환경 섬유 소재가 도입되면 기존에 축적되어있는 여러 소재 관련 데이터가 존재하지 않기 때문에 제품의 공정 결과 데이터 확보가 어렵다. 따라서 소수의 데이터를 활용하여 사전에 다양한 공정 조건의 결과값을 예측해야 할 필요가 있으며, 이로 인해 발생하는 각종 비용 절감과 실험으로 요구되는 시간을 단축시킬 수 있다. 하지만 방사 공정은 각 공정에서 이루어지는 작업 표준화 수준이 낮으며, 노동 집약적 산업으로, 현장 작업자의 수작업을 통해 제품이 주로 생산되고 있다(Jo et al., 2011). 이로 인해 생산 현장의 다양한 의사결정이 작업자의 암묵지 형태의 지식이나 노하우에 의존하고 있어 투입 원료, 용수 등 공정 조건에 따른 알맞은 물성값을 예측할 수 없는 문제점이 존재한다. 또한, 각 공정의 입력 변수가 물성값에 영향을 끼치는 정도에 대한 표준화가 부족하다는 문제점이 존재한다(Korea Institute of Industrial Technology, 1997). 방사 공정은 최초 공정 조건 설정값에 큰 영향을 받는다. 일련의 세부 공정으로 구성되어 있지만 각 세부 공정 종료 시점에 제품의 불량 판별을 할 수 없고, 모든 공정이 종료된 후 물성값 검사를 통해 확인해야 한다. 산업 특성상 비교적 긴 생산 소요 시간으로 인해 1회 제품이 생산되어 물성값을 사전에 예측하는 것이 매우 중요하다. 이러한 문제에 대응하기 위해 최근에는 인공지능(Artificial Intelligence, AI) 기법을 활용한 섬유산업의 지능화에 관한 다양한 연구가 진행되고 있다(Park et al., 2021). AI 기법을 섬유산업에 도입하면 현장에서 발생하는 다양한 사건들을 즉각적으로 대응할 수 있으며, 사전에 해결방안을 도출할 수 있다. 이를 섬유산업의 생산 현장에 적용하면 제품 품질이나 설비 고장을 사전에 예측하여 설비 유지보수나 에너지, 재생산 등의 제반 비용을 절감할 수 있다. 본 연구에서는 단순히 예측 모델을 개발하는 기존 연구와 다르게 분류 모델과 회귀 모델을 적절한 목적에 맞게 활용될

수 있는 알고리즘을 제안한다. 또한, 탐색 기법을 활용하여 기존에 확보되지 않은 공정 조건 데이터를 생성하여 물성값을 예측하고 최적의 공정 조건을 도출하고자 한다. 본 논문에서는 이러한 목적을 달성하기 위한 생분해성 섬유 개발을 위한 AI 기법 기반의 물성값 예측 알고리즘을 제안한다.

2. 연구 배경

2.1 방사 공정

방사 공정은 섬유를 고분자로 만드는 과정인 중합과정을 거쳐 중합된 고분자 칩을 건조, 용융, 섬유 구조물 형성, 냉각 및 연신, 권취 등 일련의 공정을 통하여 요구되는 물성값에 맞는 섬유를 형성시키는 공정이다(Kim, 2019). 다음의 <Figure 1 (a)>는 방사 공정의 일부 과정이며(Hong, 2012), <Figure 1 (b)>는 방사 공정을 통해 생산되는 섬유이다(TEXEYE, 2016). <Figure 2>는 방사 공장의 전체적인 구성을 보여주며, 각 공정에 대한 간략한 설명은 다음과 같다.



(a) Spinning process



(b) Fiber produced through the spinning process

Figure 1. Spinning process in Textile Industry




Figure 2. The Process of Spinning Process

- 원료투입(Raw material input process): 생산 라인에 제품의 원재료를 투입 및 분배하는 공정이다. 주로 액체상태의 원료에 다양한 종류의 물질을 혼합하여 조제하는 공정이다.
- 건조공정(Dry process): 섬유 고분자를 쉽게 증발할 수 있는 용매에 녹인 다음 이 용액을 뜨거운 공기 속으로 압출하여 용매를 증발시켜 섬유 형태로 고화시키는 공정이다.
- 용융공정(Melting process): 열에 의해 분해되지 않는 고분자를 용융시키는 공정이며, 융점 이상의 온도에서 제품을 용융시키는 공정을 의미한다.
- 압출공정(Extrusion process): 용융된 고분자가 노즐의 기어펌프를 통해 섬유상으로 압출되는 공정이다.
- 고화공정(Solidification): 용융상태에서 형성된 섬유의 형태를 고화시키는 공정으로 용융된 섬유 분자를 냉각 공기를 통과시켜 고화시키는 공정이다.
- 권취공정(Winding process): 권취 장치를 통해 섬유를 긴 모양으로 늘리는 공정이며, 다양한 속도로 제품을 가늘고 긴 모양의 섬유로 생산한다.

방사 공정은 생산되는 섬유의 물성값 예측이 중요하지만 각 공정의 설정 변수가 물성값에 영향을 끼치는 정도에 대한 표준화가 부족한 상태이고, 이러한 설정 변수는 주로 작업자의 주관에 의하여 임의 조정된다. 상술한 바와 같이 긴 생산 시간으로 인해 하루에 1회만 생산을 하고 모든 공정이 종료된 후에만 불량량을 확인할 수 있다. 그러므로 최초 제품 생산 계획 및 공정을 가동할 때부터 제품의 물성값을 예측하는 것이 중요하다.

2.2 Machine Learning/Deep Learning(분석모형)

머신러닝(Machine Learning, 기계 학습)은 AI의 한 분야로서, 데이터에서 얻어지는 경험으로부터 특정한 목표 작업에 대한 성능을 향상시키는 일련의 과정으로 정의된다. 인간이 학습을 수행하듯이 컴퓨터가 입력받은 데이터를 통해 스스로 학습을 수행하게 함으로써 새로운 지식을 얻어내는 기법이라고 할 수 있으며, 특히 예측과 최적화에 주로 활용되고 있다(Samuel AL, 1959).

딥러닝(Deep Learning)은 기존의 머신러닝의 단점을 보완하기 위해 컴퓨터가 스스로 여러 비선형 변환기법의 조합을 이용하여 다량의 복잡한 학습 데이터들을 높은 수준의 추상화된 정보로 추출하거나 분류하는 것이다. 이러한 딥러닝 기술은 사람이 만든 프로그램 없이 기존 자료의 학습된 속성을 바탕으로 새로운 자료를 정확하게 처리할 수 있다(Gers *et al.*, 2000; LeCun *et al.*, 1995) 딥러닝의 구조는 인간의 뇌를 모방한 인공신경망(ANN : Artificial Neural Network)에서 비롯되었다. 다중처리 계층으로 구성된 딥러닝은 여러 수준의 추상화를 통해 자료의 표현을 정확하게 학습할 수 있다(Schmidhuber, 2015).

머신러닝 방법론은 대표적으로 지도학습(Supervised Learning)

과 비지도학습(Unsupervised Learning)으로 구분된다. 지도학습은 인간이 직접 컴퓨터의 학습 과정을 지도한다. 지도학습을 위해서는 훈련 데이터 세트(Training Set)가 필요하며, 학습 모델의 입력이 되는 특성 변수(Feature Variable)와 그 결과에 해당하는 목표 변수(Target Variable)를 가지고 있어야 한다. 훈련 데이터 세트를 활용하여 컴퓨터는 일반화 모형을 구축하며, 새로운 데이터에 대하여 목표 변수를 예측해내는 것이 지도학습의 목적이다(Bonnin, 2018).

비지도 학습은 목표 변수 없이 특성 변수로만 구성된 데이터를 제공하여 인간의 지도 없이 컴퓨터가 스스로 유사한 데이터를 그룹화하고 범주를 할당하는 작업을 수행하도록 한다(Marsland, 2016; Bonnin *et al.*, 2018). 목표 변수 없이 입력된 데이터 간의 상호 유사성과 차이를 분석하여, 군집을 만들거나 연관성 규칙을 찾아내는 것이 비지도 학습의 목적이다(Jo, 2018).

지도학습의 대표적인 유형은 크게 분류(Classification)와 회귀(Regression)로 나뉜다. 분류란 학습 데이터로 주어진 데이터의 특성 변수와 목표 변수를 머신러닝 알고리즘으로 학습해 모델을 생성하고, 이렇게 생성된 모델에 새로운 데이터 값이 주어졌을 때 미지의 목표 변수를 예측하는 것이다(Kwn, 2006). 회귀는 여러 개의 특성 변수에 따라 목표 변수가 어떤 관계를 나타내는지를 모델링하고 예측하는 것으로 회귀의 예측값은 연속형 숫자 값이다(Kwn, 2006). 이러한 AI 기법을 활용한 친환경 섬유 개발 관련 연구가 활발히 진행되고 있다. 염색가공 산업의 에너지 효율화를 위한 제조 현장 빅데이터 활용에 관한 연구 논문에서는 염색가공 산업의 에너지 효율화를 위한 빅데이터 활용방안에 대하여 논하였고, 이를 위해 염색 공정에서 수집한 데이터를 활용하여 해당 작업을 표준화하였다. 표준화된 데이터를 바탕으로 유의한 변수들을 추출하고 이를 바탕으로 제조 현장 빅데이터의 활용방안을 제시했다(Park *et al.*, 2018). 본 논문에서 제안하는 알고리즘은 단순 예측 모델 개발에 그치지 않고, 방사 공정에서 생산되는 섬유 소재의 물성값을 도출하기 위해 전처리한 데이터를 기준으로 불량을 판별하기 위해 분류 모델을 생성하고, 그리드 서치 기법을 활용하여 생성된 시뮬레이션 데이터를 회귀 모델에 대입하여 모든 공정 조건 경우의 수에 대한 물성값을 예측하는 것이다.

3. 물성 예측을 위한 AI 기반 알고리즘

본 장에서는 방사 공정을 통해 생산되는 제품의 물성값 예측을 위한 AI 기반 알고리즘을 제안한다. 이를 위해 먼저 데이터 구축과정을 설명하고, 데이터 전처리와 알고리즘에 대해 다룬다.

3.1 데이터 구축

다음의 <Table 1>은 방사 공정에서 수집된 제조 현장 데이터

의 단위와 정의를 보여준다. 해당 데이터는 기존 작업자의 수기 혹은 노하우에 의존하던 정보들을 디지털화한 데이터이다. 본 논문에서는 총 50가지의 현장 데이터를 수집, 공정 설정이 변하지 않고 일정하게 유지되는 고정 변수값 데이터를 제외한 나머지 데이터를 전처리하였으며, 이를 위해서 <Table 2>와 같이 고정 변수값을 가지는 작업 공정 데이터와 <Table 3>과 같은 고정 변수값을 가지지 않는 작업 공정 데이터로 나누었다. <Table 4>는 섬유의 품질 지표에 해당하는 물성값 데이터의 단위와 정의를 나타낸다. 이 중에서 핵심 지표인 강도(Elongation)와 신도

(Tenacity)를 목표변수로 설정하여 최적의 공정 변수값을 예측하는게 본 연구의 목적이다. 방사 공정 프로세스 핵심 인자 도출을 위해 방사 공정 장비에서 수집되는 데이터를 대상으로 총 317개의 데이터 세트를 대상으로 하였으며, 고정 변수값을 가지지 않는 작업 공정 데이터 중 값이 동일한 변수들은 하나로 정의하여 분산분석(ANOVA)을 진행하였다. ANOVA란 두 개 이상 다수의 집단을 서로 비교하여 유의변수를 도출하는 방법으로 특성 변수가 목표 변수에 영향을 미치는지 확인하기 위해 진행하였다. 일반적으로 강도가 높아지면 신도는 낮아질 것으

Table 1. Definitions of Spinning Process Data

No	Data	Unit	process	Definition
1	Chip input	kg	Input	Input amount of raw material chips
2	Functional MB concentration	%		The ratio of functional MB concentration to total raw material
3	Functional MB chip input	kg		Input amount of functional MB concentration
4	Drying time	min	Dry	Time to dry the moisture contained in the combined raw materials
5	Drying temperature	℃		Temperature to dry the moisture contained in the combined raw materials
6	Melting temperature	℃	Melting	The temperature at which solid state raw materials are heated
7	Extruder pressure	MPa		Equipment pressure to heat solid raw materials
8	Hole CS type	shape	Extrusion	The type of pack that determines the shape
9	Hole Number	num		Number of entrances in the pack
10	Length	mm		Height of pack
11	Diameter	mm		Diameter of pack
12	Sand particle size for filter	-		Size type of metal powder
13	Mesh type	-		Maximum number of filters to insert in a pack
14	Spinbeam temperature	℃		Temperature of nozzle
15	Manifold temperature	℃		Same as spinbeam temperature
16	Pack front pressure	Mpa		Pressure in front of the pack
17	Pack end pressure	Mpa		Pressure after the pack
18	Quenching type	Cross/Candle	Solidification	Types of systems that solidify the shape of fibers
19	Wind speed	m/sec		The speed of the wind solidifies the shape of the fibers
20	Solidification temperature	℃		The temperature that solidifies the shape of the fibers
21	Oil method	JET/Roller		Method of adding oil to yarn
22	Oil brand	-		Brand of oil used
23	Oil concentration	%		The concentration of oil in the emulsion in the oil box
24	Oiling rpm	rpm		Oiling speed
25	Setting distance	m		Distance from refueling equipment when using the JET method
26	Migration pressure	kg/cm ²	Winding	Migration equipment pressure
27	Interace pressure	kg/cm ²		Interace equipment pressure
28	GODET R/O speed	m/min		Rotation speed of GODET roller
29	GODET R/O temperature	℃		The surface speed of GODET roller
30	Winding R/O speed	m/min		The speed of the motor when the last yarn is wound
31	Winding angle	°		Angle for even winding when the yarn is wound
32	Contact press #1	kg/cm ²		Wind prep pressure
33	Contact press #2	kg/cm ²		Pressure in the winding progress phase
34	Winding tension	g		The pressure of the winding thread
35	Draw ratio	m/min		The ratio of GODET roller rotation speed

로 예측되었으나 분석 결과, 두 변수 사이의 상관관계는 존재하지 않으며, 강도와 신도 사이의 산포는 <Figure 3>과 같다. 다음의 <Figure 4>는 두 변수 사이의 상관관계를 나타낸다. 따라서 강도와 신도에 영향을 미치는 유의변수 추출을 위해 각 물성값에 대하여 ANOVA 분석을 진행하였다. 분산분석의 평가지표인 유의확률(p-Value)은 낮을수록 신뢰도가 좋다고 볼 수 있으며, 통상적으로 유의수준이 95% 이내일 경우 두 변수 간의 연관도가 높다고 볼 수 있다. 강도의 경우, <Table 5>와 같이 p-Value로 유의수준 0.05보다 작은 유의변수가 없는 것으로 분석되었다. 신도의 경우, <Table 6>과 같이 모든 특성 변수의 p-Value가 유


의수준 0.05보다 작으므로, 통계적으로 모두 유의미한 변수들이라고 분석되었다. 상관관계 분석을 활용하여 각 공정 핵심인자 간의 영향력을 분석한 결과, 강도의 경우 모든 특성 변수가 목표 변수에 영향을 주지 않는 것으로 확인되었고, 반대로 신도의 경우 모든 특성 변수가 목표 변수에 영향을 주는 것으로 관찰되었다. 따라서 ANOVA를 활용하여 유의미한 특성 변수 선정하는 데 한계가 존재하여 현장 전문가가 핵심으로 관리하는 변수인 Spinbeam temp, GODET R/O A 속도, GODET R/O B 속도, GODET R/O B 온도, 권취 R/O 속도, 연신비 총 6가지를 특성 변수로 선정하였다.

Table 2. Process Data with Fixed Variable Values

No	Data	Unit	Value
1	Chip input(A)	kg	40
2	Chip input(B)	kg	41
3	MB concentration	%	100
4	Functional MB chip input(A)	kg	0
5	Functional MB chip input (B)	kg	0
6	Drying time	min	300
7	Drying temperature	℃	85
8	Melting temperature#1 (A)	℃	250
9	Melting temperature#2 (A)	℃	258
10	Melting temperature#3 (A)	℃	252
11	Melting temperature#4 (A)	℃	252
12	Melting temperature#1 (B)	℃	250
13	Melting temperature#2 (B)	℃	258
14	Melting temperature#3 (B)	℃	252
15	Melting temperature#4 (B)	℃	252
16	Extruder pressure(A)	MPa	160
17	Extruder pressure(B)	MPa	160
18	Hole CS type	shape	O
19	Hole Number	num	12
20	Length	mm	0.5
21	Diameter	mm	0.28
22	Sand particle size for filter	-	Mesh
23	Quenching type	Cross/Candle	Cross
24	Wind speed	m/sec	0.4
25	Solidification temperature	℃	20
26	Oil method	JET / Roller	Roller
27	Oil brand	-	#1308
28	Oil concentration	%	15
29	Oiling rpm	rpm	17
30	Setting distance	m	1.6
31	Interace pressure	kg/cm ²	30
32	GODET R/O A temperature	℃	90
33	Contact press #1	kg/cm ²	12
34	Contact press #2	kg/cm ²	15
35	Winding tension	g	16

Table 3. Process Data with no Fixed Variable Values

No	Data	Unit	value
1	Mesh #1 type	-	#30, #36
2	Mesh #2 type	-	#30, #36
3	Mesh #3 type	-	#30, #36
4	Mesh #4 type	-	#30, #36
5	Spinbeam temperature	℃	254, 256, 258, 260, 262
6	Manifold #A temperature	℃	254, 256, 258, 260, 262
7	Manifold #B temperature	℃	254, 256, 258, 260, 262
8	Pack front pressure	Mpa	54, 69
9	Pack end pressure	Mpa	54, 69
10	Migration pressure	kg/cm ²	1.2, 1.8
11	GODET R/O A speed	m/min	(1000 ~ 3675)
12	GODET R/O B speed	m/min	(4105 ~ 4520)
13	GODET R/O B temperature	℃	95, 100, 105
14	GODET R/O speed	m/min	(4000 ~ 4400)
15	Draw ratio	m/min	(15 ~ 300)

**Figure 3.** Correlation of Elongation and Tenacity**Table 4.** Definitions of Physical Properties Data

No	Data	Unit	Definition
1	Average temperature	℃	Average temperature of yarn
2	Average tenacity	g	Average tenacity of yarn
3	Elongation	g/d	Average of the maximum force when breaking by pulling 20 times
4	Tenacity	%	Increase rate when elongation is at the maximum value in the 20th experiment
5	Microtome	-	Close-up photo of yarn cross section
6	Dimensional change rate - category	-	Classification of increase/decrease in yarn
7	Dimensional change rate - rate of change	%	Change in length after natural drying in 100 hot water for 30 minutes
8	Unevenness	%	A ratio of equal thickness of yarn
9	Count	tex	Thread thickness

Table 5. ANOVA Table of Physical Property for Tenacity

No	Variable	df	Sum_df	Mean_sq	F-Value	PR(>F)
1	Mesh type	1	0.059609	0.059609	0.124723	0.724457
2	Spinbeam Temp	8	7.754576	0.969322	2.028149	0.056625
3	Mainfold A Temp	6	1.227498	0.204583	0.428057	0.859386
4	Pack front pressure	1	0.135039	0.135039	0.282547	0.595813
5	Pack end pressure	1	0.010676	0.010676	0.022338	0.881390
6	GODET R/O A speed	52	15.484797	0.297785	0.623066	0.974760
7	GODET R/O B speed	6	0.092437	0.015406	0.032235	0.999855
8	GODET R/O B temperature	2	0.330029	0.165041	0.345266	0.708586
9	Winding R/O speed	4	0.061703	0.045896	0.096030	0.983595
10	Draw ratio	53	6.844680	0.129145	0.270215	1.000000
11	Residual	152	72.646013	0.477934	NaN	NaN

Table 6. ANOVA Table of Physical Property for Elongation

No	Variable	df	Sum_df	Mean_sq	F-Value	PR(>F)
1	Mesh type	1	54.670305	54.670305	0.947628	3.326495e-01
2	Spinbeam Temp	8	2152.08699	269.010874	4.662902	7.097066e-05
3	Mainfold A Temp	6	104.37003	17.395062	0.301517	9.347916e-01
4	Pack front pressure	1	14.883317	14.883317	0.257980	6.126187e-01
5	Pack end pressure	1	6.042274	6.042271	0.104734	7.468904e-01
6	GODET R/O A speed	52	2262.2465	43.504742	0.754090	8.687656e-01
7	GODET R/O B speed	6	51.076640	8.512773	0.147556	9.891591e-01
8	GODET R/O B temperature	2	34.183775	19.091887	0.330929	7.190317e-01
9	Winding R/O speed	4	3.207456	0.801864	0.013899	9.996135e-01
10	Draw ratio	53	45.618087	41.447521	0.718431	9.071079e-01
11	Residual	152	5826.8643	57.691729	NaN	NaN

3.2 데이터 전처리

본 연구에서 특성 변수로 선정한 6개 데이터의 유형은 수치형(numerical)에 해당한다. 수치형 변수는 데이터의 분포와 각 특성 변수 간의 숫자 규모가 큰 차이를 갖고 있기 때문에 모델의 정확도와 성능 측정이 어렵고 오차값이 크게 나타난다. 때문에 본 논문에서는 서로 다른 변수의 값 범위를 일정하게 맞춰주는 전처리 기법인 표준화(Standardization)와 정규화(Normalization)를 진행하였다. 표준화는 데이터 전처리과정에서 각 데이터의 평균이 0이고 분산이 1인 가우시안 정규 분포를 가진 값으로 변환하는 것을 의미하며, 정규화는 데이터가 0부터 1 사이의 정규 분포 값을 갖도록 하는 기법을 의미한다(Bonnin, 2018). 표준화와 정규화는 데이터의 형태와 학습 모델에 따라 성능 예측 결과값이 다르므로 본 연구에서는 모든 특성 변수에 대해 표준화와 정규화를 적용하였다.

3.3 알고리즘

본 논문에서 제안하는 알고리즘은 방사 공정에서 생산되는 섬유 소재의 물성값을 도출하기 위해 전처리한 데이터를 기준

으로 불량률 판별하기 위한 분류 모델을 생성하고, 그리드 서치 기법을 활용하여 생성된 모든 공정 조건 경우의 수에 대한 시뮬레이션 데이터를 학습된 분류 모델을 활용하여 예측한다. 제품을 불량으로 예측한 데이터를 제거하여 회귀 모델 학습을 위한 데이터 세트를 구축하고 이를 회귀 모델에 대입하여 최적 공정값에 따른 물성값을 예측하는 것이다. 분류 모델을 통해 강도와 신도를 먼저 예측하지 않고 회귀 모델을 구축하여 예측할 경우, 데이터 분포가 부족한 category의 데이터와 다른 category와의 불균형을 해소할 수 없다. 또한, 회귀 모델의 성능지표가 제안하는 방법론으로 생성된 모델보다 낮게 학습되었기 때문에 분류 모델을 먼저 구축하였다. <Figure 4>는 본 논문에서 제안하는 알고리즘의 개념도이며, 각 구성 요소들에 대한 설명과 절차는 다음과 같다.

- 1) 분류 모델 학습을 위한 데이터 전처리(Data preprocessing for classification): 본 연구에서 제안하는 알고리즘의 목표 함수인 강도와 신도는 수치형 데이터로 분류 모델의 경우 물성값의 범주화가 필요하기에 기준점을 설정하였다. 모델 학습을 하기 위해서 정규화와 표준화와 데이터의 불균형 문제를 해결하기 위해 Synthetic Minority Over-sampling

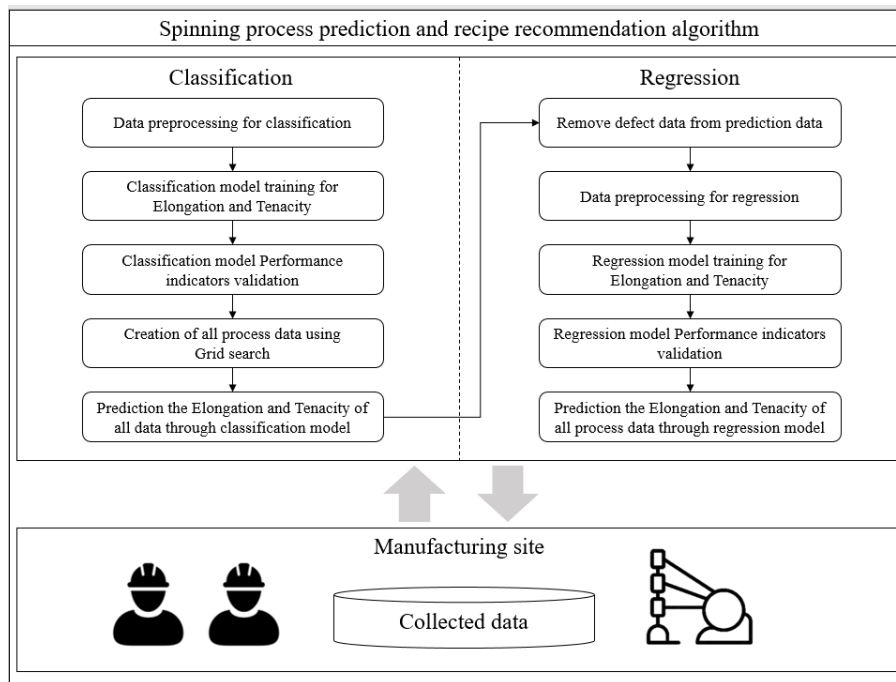


Figure 4. Spinning Process Prediction and Recipe Recommendation Algorithm

Technique(SMOTE) 기법을 활용하여 전처리를 진행하는 과정이다. SMOTE란 데이터가 부족할 때 분류 모델에서 클래스 간 불균형을 해결하기 위해 사용하는 기법이다.

- 2) 분류 모델 학습(Classification model training): 전처리한 데이터를 여러 분류 모델에 적용하여 학습하는 과정으로, 여기서 주요 분류 모델로 K-Nearest Neighbors(KNN), Xgboost, RandomForest, Multi Layer Perceptron를 활용하였으며, 모델별로 최적의 하이퍼 파라미터값을 탐색하고 적용하였다. 제안하는 알고리즘에서 분류 모델을 구축한 이유는 사전에 불량품 판별을 하고 양품으로 판별되는 데이터를 대상으로 모델을 학습시키기 위함이다.
- 3) 분류 모델 유효성 검증(Classification model validation): 해당 절차는 1)~2)의 과정으로 전처리된 데이터 세트를 기반으로 학습된 모델을 검증하기 위한 절차로, 분류 모델의 주요 성능지표인 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1 Score를 사용하였다. 정확도는 실제 데이터의 목표 변수와 예측 데이터의 목표 변수가 얼마나 동일한지 판단하는 지표이며, 정밀도는 예측 데이터의 목표 변수가 True라고 분류한 것 중에서 실제 데이터의 목표 변수가 True인 것의 비율을 나타낸다. 재현율은 실제 데이터의 목표 변수가 True인 것 중에서 예측 데이터의 목표 변수가 True라고 예측한 것의 비율을 나타내며, F1 Score는 정밀도와 재현율의 조화평균을 의미한다. 해당 4개의 성능평가지표를 활용하여 모델별로 성능을 분석하였다.
- 4) 공정 시뮬레이션 데이터 생성을 위한 그리드 서치(Grid search): 실제 현장에서 수집된 특성 변수들 이외에 변수 별로 설정 가능한 모든 경우의 수를 도출하는 과정으로

요구되는 제품의 물성값 달성을 위한 모든 공정 조건을 생성한다. 공정 시뮬레이션 데이터는 변경되는 모든 변수의 조합을 생성하는 그리드 서치 기법을 활용하였다.

- 5) 공정 시뮬레이션 데이터 예측(Prediction of simulation data): 4)에서 도출된 공정 시뮬레이션 데이터를 1)~3) 과정에서 학습된 분류 모델을 활용하여 목표 변수를 예측하는 과정이다.
- 6) 불량 예측 데이터 제거(Remove defect results): 5)의 과정으로 예측된 분류 데이터에서 제품을 불량으로 예측한 데이터를 제거하여 회귀 모델 학습을 위한 데이터 세트를 구축하는 단계이다.
- 7) 회귀 모델 학습을 위한 데이터 전처리(Data preprocessing for regression): 앞서 생성된 공정 시뮬레이션 데이터의 물성값을 예측하기 위해서 정규화와 표준화를 이용하여 모델 학습 이전에 전처리하는 과정이다.
- 8) 회귀 모델 학습(Regression model training): 7)에서 전처리한 데이터를 여러 회귀 모델에 적용하여 학습하였으며, 주요 회귀 모델로는 Ridge, Lasso, KNN, RandomForest, GradientBoosting, Long-Short Term Memory(LSTM), Deep Neural Network(DNN)로 모델별로 서로 다른 하이퍼파라미터를 적용하였다.
- 9) 회귀 모델 유효성 검증(Regression model validation): 학습된 회귀 모델을 검증하기 위한 과정으로 회귀 모델의 주요 평가지표인 MSE(Mean Squared Error), MAE(Mean Absolute Error), 그리고 R^2 (R Squared Score)를 사용하였다. MSE는 실제 목표 변수값과 예측 목표 변수값 오차의 제곱 값들의 평균을 나타내며, MAE는 실제 목표 변수값과 예측 목표 변수값 오차의 절대값 평균을 설명한다. 또

한 R^2 는 실제 목표 변수값의 분산대비 예측 목표 변수값의 분산을 계산하여 예측 정확도를 측정하는 지표이다.

- 10) 공정 시뮬레이션 데이터 예측(Prediction data): 8)에서 구축된 회귀 모델에 그리드 서치 기법을 통해 생성된 공정 시뮬레이션 데이터를 기반으로 제품의 불량을 제외한 모든 공정 조건의 목표 변수에 해당하는 물성값을 예측하였다.

4. 알고리즘 구현 및 결과 분석

4.1 알고리즘 구현

본 연구에서 적용한 머신러닝은 모두 Python 3.8.5 환경에서 구축하였으며, Keras, Scikit-Learn(Sklearn), Pandas, Numpy 등 데이터 분석 및 통계 라이브러리를 활용하였다. 머신러닝 모델에 다음과 같은 데이터 세트를 구축하여 모델의 성능을 비교하였다. 기존의 표준화와 정규화 이외에 데이터의 불균형과 불충분을 해소하기 위해 이와 같은 데이터 세트를 구축하였으며, 분류 모델의 경우 아래 C-Set 1과 C-Set 2, C-Set 3 데이터를 대상으로 학습을 진행하였다.

- 1) C-Set 1 : 방사 공정의 특성상 한 번의 제품 생산 과정을 거치면 평균 2개에서 4개의 제품이 동시에 생산된다. 이는 공정에서 열을 가하여 화학물을 혼합할 때 균등하게 화학 성분이 결합되지 않는 경우가 발생하는 등, 설비에서 각각의 미세한 오차가 발생하는 경우가 생기기 때문에 하나의 작업 ID 당 평균 2~4개의 수집 데이터가 생성된다는 의미이다. 생성된 수집 데이터의 공정값(특성 변수)은 모두 동일하기 때문에 작업 ID 당 생성된 데이터의 물성값(목표 변수) 평균으로 기존 991개의 데이터에서 317개의 데이터로 전처리하여 데이터 세트를 구축하였다.

- 2) C-Set 2 : C-Set 1의 317개 데이터의 범주별 분포 불균형 문제를 해결하기 위해 상술한 SMOTE 기법을 활용하여 425개의 데이터 세트를 구축하였다.

- 3) C-Set 3 : C-Set 1 데이터 세트가 불충분할 수도 있으므로 하나의 작업 ID 당 생성되는 모든 데이터와 1)의 데이터를 합친 1,123개의 데이터 세트를 구축하였다.

회귀 모델의 경우 아래 R-Set 1과 R-Set 2, R-Set 3과 같이 데이터 세트를 대상으로 학습을 진행하였다.

- 4) R-Set 1 : C-Set 1 데이터에서 판단되는 불량 데이터로 분류된 89개를 제외하고 228개의 데이터를 대상으로 하였다.
- 5) R-Set 2 : R-Set 1 데이터의 수가 불충분했기 때문에 하나의 작업 ID 당 생성되는 모든 데이터와 4)의 데이터를 합친 총 905개의 데이터를 대상으로 하였다.
- 6) R-Set 3 : Set 2의 데이터의 불균형 문제를 해결하기 위해 모델의 노이즈를 유발하는 이상치 데이터를 제거하고 불균형 대상이 되는 표본을 선정하여 단순히 데이터의 수를 늘리는 표본추출방법인 Random sampling 기법을 활용하여 1,440개의 데이터를 대상으로 하였다.

물성값인 강도와 신도의 경우 위에서 언급했듯이 분류 모델의 경우 데이터 전처리 단계에서 범주화가 필요하다. 데이터 세트를 살펴보면 강도의 경우 불량 데이터를 제외하고 최소값이 2.6, 최대값이 4.5이며, 총 6개의 category로 구성하였고 범주화 시 각 category의 범위를 0.3으로 구분했다. 신도의 경우 불량 데이터를 제외하고 최소값이 20, 최대값이 45이며, 이 또한 총 6개의 category로 구성되어야 하므로 category의 범위를 5로 구분하였다. 이때 0에 해당하는 category는 불량 데이터로 판별한다. 다음의 <Table 7>은 분류 범주에 해당하는 물성값의 범주화 결과를 정리한 표이다. 모델의 성능을 높이기 위해 데이터는 Sklearn Package의 StandardScaler와 MinMaxScaler를

Table 7. Categories of Property Data

	Preprocessing data	Category
Elongation 0.3	0, [2.7, 3.0), [3.0, 3.3), [3.3, 3.6), [3.6, 3.9), [3.9, 4.2), [4.2, 4.5)	7
Tenacity 5	0, [20, 25), [25, 30), [30, 35), [35, 40), [40, 45), [45, 50)	7

Table 8. Data Variables for Grid Search

	Data
Spinbeam temperature	[250, 254, 255, 256, 258, 260, 262, 263, 268]
GODET R/O A speed	[80, 90, 1000, 1140, 1168, 1207, 1225, 1237, 1240, 1250, 1256, 1260, 1270, 1280, 1290, 1291, 1297, 1300, 1310, 1320, 1329, 1330, 1340, 1350, 1354, 1360, 1370, 1380, 1387, 1390, 1393, 1400, 1410, 1420, 1430, 1440, 1450, 1460, 1461, 1470, 1480, 1490, 1498, 1495, 1500, 1537, 1568, 1575, 1607, 2000, 2050, 2100, 2499, 2500, 2562, 2624, 3000, 3001, 3076, 3151, 3500, 3588, 3675]
GODET R/O B speed	[4039, 4105, 4140, 4205, 4241, 4410, 4520]
GODET R/O B temperature	[80, 95, 100, 105]
Winding speed	[4000, 4100, 4200, 4300, 4400]

활용하여 표준화와 정규화를 진행하였으며, 모델 구축을 위해 훈련 데이터 세트와 테스트 데이터 세트를 8:2 비율로 분리하여 학습하였다. 하이퍼파라미터는 max_depth, min_samples_leaf, n_estimators, learning_rate 등 각각 모델에 따라 최적의 값을 비교 분석하여 도출하였다. 앞서 설명한 그리드 기법으로부터 도출된 공정 시뮬레이션 데이터의 변수는 <Table 8>과 같다.

물성값인 강도를 예측하기 위한 분류 모델별 성능지표 평가 결과는 <Table 9>와 같으며, 신도를 예측하기 위한 분류 모델별 성능지표 평가 결과는 <Table 10>과 같다.

학습된 모델들의 성능지표 비교결과, 물성값 강도의 경우 C-Set 2를 적용한 Xgboost의 정확도와 평가지표 성능이 제일 좋은 것으로 나타났다. 전체적으로 데이터의 분포나 편향이 심했기 때문에 SMOTE를 써도 모델의 성능이 크게 높아지지 않았으며, 데이터의 양이 너무 적었기 때문에 전체적으로 학습 데이터

Table 9. Model Analysis Results of Elongation

Xgboost				
Set	Accuracy	Precision	Recall	F1 Score
1	0.63	0.64	0.58	0.59
2	0.71	0.68	0.7	0.68
3	0.55	0.55	0.63	0.56
MLP				
1	0.62	0.52	0.51	0.51
2	0.59	0.36	0.4	0.38
3	0.51	0.42	0.49	0.44
Randomforest				
1	0.62	0.41	0.42	0.4
2	0.6	0.38	0.41	0.39
3	0.55	0.55	0.63	0.56
KNN				
1	0.6	0.38	0.41	0.39
2	0.6	0.58	0.69	0.59
3	0.53	0.41	0.38	0.39

Table 10. Model Analysis Results of Tenacity

Xgboost				
Set	Accuracy	Precision	Recall	F1 Score
1	0.75	0.7	0.62	0.64
2	0.72	0.83	0.57	0.64
3	0.77	0.85	0.58	0.64
MLP				
1	0.77	0.69	0.72	0.7
2	0.67	0.5	0.53	0.49
3	0.76	0.87	0.55	0.58
Randomforest				
1	0.73	0.53	0.47	0.49
2	0.73	0.54	0.57	0.54
3	0.55	0.55	0.63	0.56
KNN				
1	0.71	0.51	0.46	0.48
2	0.66	0.5	0.47	0.49
3	0.73	0.59	0.54	0.55

와 테스트 데이터 모두 제대로 예측하지 못한 상태인 과소적합(Underfitting) 성향이 크게 나타난 것을 알 수 있었다. 물성값인 신도의 경우 Xgboost의 C-Set 3과 MLP의 C-Set 1의 Accuracy는 동일하게 나왔지만 Xgboost C-Set 3의 경우 학습 데이터에 대해 과하게 학습되어 이외의 데이터에 대해선 제대로 예측하지 못하는 과적합(Overfitting)을 보였기 때문에 C-Set 1을 적용한 MLP의 평가지표 성능이 제일 좋은 것으로 판단하였다.

회귀 모델의 경우 불량 데이터를 제외한 데이터 세트를 대상으로 모델에 적용했으며 물성값인 강도를 예측하기 위한 모델별 평가지표는 <Table 11>과 같으며, 신도를 예측하기 위한 모델별 평가지표는 <Table 12>와 같다.

다양한 알고리즘을 이용하여 모형들의 측정지표들을 종합적으로 비교해보았을 때 R-Set 1 데이터를 활용할 경우, 성능지표 R^2 값이 ridge regression, lasso regression, LSTM 모델에서 마이너스가 도출되면서 학습이 전혀 되지 않은 상태임을 확인할 수 있다. 물성값 강도의 경우 R-Set3을 적용한 LSTM 모델의 성능이 가장 좋은 것으로 나타났으며, 물성값 신도의 경우 또한 LSTM의 성능이 가장 좋은 것으로 나타났다. LSTM의 실제 물성값 대비 예측 물성값 오차 비교는 <Table 13>과 같다.

그리드 서치를 통해 생성된 공정 시뮬레이션 데이터와 최종 시뮬레이션 예측 데이터는 <Figure 5>와 같다. 생성된 시뮬레이션 데이터를 Xgboost와 MLP 모델에 대입하여 불량 예측을 하였으며, 회귀 모델 학습을 위해 생성된 불량은 제거하고 LSTM 모델에 대입하여 최종 시뮬레이션 예측 데이터를 생성하였다.

Table 11. Model analysis results of elongation

Randomforest			
Set	R^2	MAE	MSE
1	0.71	0.09	0.01
2	0.53	0.19	0.06
3	0.53	0.18	0.06
KNN			
1	0.7	0.09	0.01
2	0.54	0.2	0.07
3	0.54	0.2	0.07
Ridge			
1	0.74	0.01	0.11
2	0.53	0.19	0.06
3	0.46	0.06	0.25
Lasso			
1	0.74	0.01	0.11
2	0.54	0.2	0.07
3	0.46	0.06	0.25
LSTM			
1	0.81	0.08	0.01
2	0.95	0.04	0.01
3	0.97	0.04	0.01
DNN			
1	-1.08	0.24	0.09
2	0.49	0.19	0.06
3	0.49	0.19	0.06

Table 12. Model Analysis Results of Tenacity

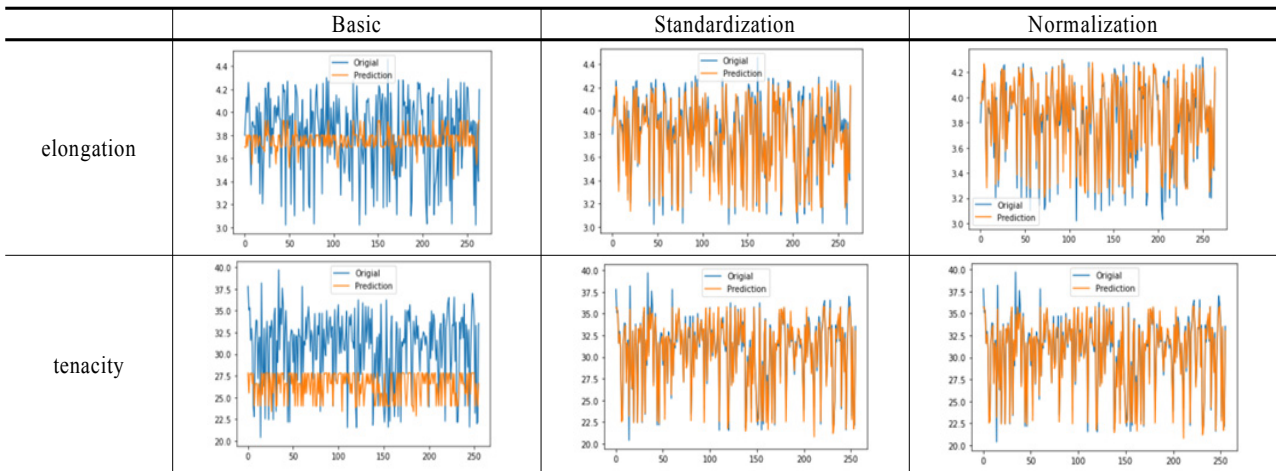
Randomforest			
Set	R^2	MAE	MSE
1	0.3	1.21	2.32
2	0.45	1.32	3.09
3	0.58	1.95	7.06
KNN			
1	0.43	1.21	1.89
2	0.4	1.39	3.37
3	0.52	2.1	8.03
Ridge			
1	-0.01	3.55	1.88
2	0.33	8.05	7.52
3	0.4	11.37	3.37
Lasso			
1	-0.01	3.35	1.88
2	0.33	5.45	6.88
3	0.25	14.1	3.75
LSTM			
1	-10.8	6.43	45.2
2	0.97	0.04	0.01
3	0.96	0.56	0.62
DNN			
1	0.49	0.19	0.06
2	0.36	2.27	1.2
3	0.49	0.19	0.06

4.2 결과 분석

본 논문에서 제안하는 알고리즘을 구현 및 적용하여 도출된 결과를 종합적으로 정리하면 다음과 같다.

- 1) 분류 모델의 경우 물성값 강도의 Accuracy와 Precision, Recall, F1 score가 71%, 68%, 70%, 68%인 Xgboost가 최종 모형으로 선정되었으며, 신도의 경우 77%, 69%, 72%, 70%인 MLP가 최종 모형으로 선정되었다.
- 2) 분류 모델의 경우 전체적으로 데이터의 분포나 편향이 심했기 때문에 SMOTE를 활용하더라도 모델의 성능이 크게 높아지지 않았으며, 전체적으로 과소적합 성향이 나타난 것으로 관찰된다.
- 3) 회귀 모델의 경우 물성값 강도의 R^2 와 MAE, MSE가 0.97, 0.04, 0.01인 LSTM의 성능이 가장 우수하기 때문에 최종 모델로 선정되었으며, 신도의 경우 또한 0.97, 0.04, 0.01인 LSTM이 최종 모델로 선정되었다.
- 4) LSTM의 경우 은닉 레이어를 1개로 설정하여 노드 수만을 조절할 경우 예측 성능이 높지 않은 것을 확인할 수 있었으며, 노드 수에 상관없이 은닉 레이어의 수를 조절할 경우 모델의 성능이 좋아지는 것을 확인할 수 있다. 결론적으로 은닉 레이어의 수를 4개로 설정한 경우 모델의 성능이 가장 좋게 관찰되었다. 또한, 데이터를 전처리하지

Table 13. Comparison of LSTM's Prediction of Actual Property Value Error



0	250.0	90.0	4105.0	100.0	4000.0
1	250.0	90.0	4105.0	100.0	4000.0
2	250.0	90.0	4105.0	100.0	4000.0
3	250.0	90.0	4105.0	100.0	4000.0
4	250.0	90.0	4105.0	100.0	4000.0
...
79375	250.0	90.0	4105.0	100.0	4000.0
79376	250.0	90.0	4105.0	100.0	4000.0
79377	250.0	90.0	4105.0	100.0	4000.0
79378	250.0	90.0	4105.0	100.0	4000.0
79379	250.0	90.0	4105.0	100.0	4000.0

(a) Result data of grid search

0	250	1000	4105	100	4000	310.500000	1.531344	21.069536
1	250	1000	4105	100	4100	310.500000	1.728471	21.876719
2	250	1000	4105	100	4200	310.500000	1.833971	22.419897
3	250	1000	4105	100	4300	310.500000	1.941733	22.820576
4	250	1000	4105	100	4400	310.500000	2.062551	23.175842
...
55852	268	3675	4039	80	4400	9.904762	1.985702	23.536940
55853	268	3675	4039	100	4300	9.904762	1.660189	21.413609
55854	268	3675	4039	100	4400	9.904762	1.857223	22.443604
55855	268	3675	4039	105	4400	9.904762	1.889209	22.595192
55856	268	3675	4105	100	4400	11.700680	2.015248	22.991650

(b) Result of prediction data

Figure 5. Result Data of Grid Search and Prediction Data

않은 결과와 전처리 후의 모델의 예측 결과가 크게 차이나는 것을 확인할 수 있었다.

- 5) 그리드 서치 기법을 통하여 추출된 시뮬레이션 데이터를 분류 모델에 적용했을 시, 물성값 강도의 경우 정상과 불량 개수가 대략 65,000개, 10,000개였으며, 신도의 경우 대략 56,000개, 20,000개였다. 강도와 신도의 불량 데이터를 모두 제거하고 남은 정상 데이터 개수는 55,857개였음을 확인할 수 있었다.

5. 결 론

본 연구에서는 환경 문제에 영향을 끼치는 다수의 요인을 가지고 있는 섬유산업 내 방사 공정의 친환경 소재 개발을 위하여 물성값과 최적의 공정값을 도출할 수 있는 알고리즘을 제안하였다. 이를 위해 방사 공정의 특성을 분석하였으며, 현장 데이터를 수집하고, 다양한 데이터 전처리 기법을 이용하여 데이터를 정제하였다. 또한, 공정 프로세스 핵심 인자값과 물성값을 도출하여 강도와 신도의 상관관계를 분석하였으며, 여러 머신러닝 기반 모델을 활용하여 방사 공정 최적화 알고리즘을 구축하고 대표적인 성능지표들을 활용하여 이를 검증하였다.

현장에서 수집되는 데이터를 기반으로 방사 공정에 대해 분석하였고, 섬유 산업에서 AI 기법이 어떻게 활용될 수 있는지 연구 방향을 제안하였으며, 본 연구의 기여점과 활용방안은 다음과 같다.

- 1) AI 기법을 활용하여 기존의 공정 종료 시점에서야 불량 판별을 하는 것이 아니라 공정 중 혹은 공정 이전에 제품의 품질을 예측함으로써 불량이나 재작업으로 발생하는 각종 비용과 시간을 절감할 수 있을 것으로 기대된다. 특히 본 연구에서 목표값으로 설정한 강도와 신도는 섬유 제품의 불균형한 외관과 끊어짐, 늘어짐 등 다양한 불량 원인이 되기 때문에 사전에 물성값을 예측하여 다양한 불량을 방지할 수 있을 것으로 예상된다.
- 2) 새롭게 도입되는 친환경 소재의 경우 기존 섬유 소재들에 비해 제품 품질에 대한 불확실성이 크기 때문에 본 논문에서 제안하는 알고리즘을 활용하면, 기존 작업자의 암묵지 형태의 지식의 의존도를 낮추고, 섬유 산업에 친환경 소재 도입을 촉진할 수 있다. 새로운 소재의 섬유 제품을 생산할 경우, 다양한 공정 조건에 따른 물성값에 대한 정보가 없으므로 품질을 사전에 예측하기 힘들다. 이는 숙련된 작업자의 지식과 노하우에 의존할 수밖에 없는 상황으로 원하는 품질의 제품을 생산하기 위해 다양한 시행착오가 수반된다. 앞에서 서술한 바와 같이 방사 공정은 생산 중간에 제품의 품질을 확인하기 어려우므로 다양한 공정 조건으로 반복해서 제품을 생산할 경우 수많은 자원의 낭비와 시간이 소요된다는 의미이다. 따라서 본 알고리즘

은 작업자가 사전에 요구되는 제품의 물성값에 따라 공정 설정값을 예측할 수 있으므로 현장에서 발생할 수 있는 다양한 오류를 최소화할 수 있다.

본 연구와 앞에서 서술한 기존 연구의 차이점은 기존 연구는 단순 예측 모델 개발에 그쳤다면 본 연구는 분류 모델과 회귀 모델을 구축하고 그리드 서치 기법을 활용해서 모든 공정 조건 경우의 수에 대한 물성값 예측을 통한 최적 Recipe를 도출하였다는 점이다.

추후 연구로는 현재의 친환경 소재 개발을 위한 AI 기법의 활용방안을 방사 공정뿐만이 아니라 다양한 도메인의 섬유산업에 적용할 필요가 있다. 또한, 대부분의 경우 데이터가 모델에 크게 영향을 미치는 과적합 또는 그 반대의 경우인 과소적합이 관찰되었다. 이는 모델 학습에 필요한 학습 데이터의 양이 적은 것이 원인으로 판단된다. 따라서, 현장 데이터 축적을 통해 추가적인 연구가 필요하다.

참고문헌

- Bonnin, R. (2017), *Machine Learning for developers*, Packt, Birmingham.
- Gers, F. A., Schmidhuber, J., and Cummins, F. (1999), Learning to forget: Continual prediction with LSTM, *Ninth International Conference on Artificial Neural Networks ICANN 99*, 12(10), 2451-2471.
- Hong, S. M. (2012), "Textile, walking on the cutting edge...Huvis Jeonju Plant", *EBN Industrial Economy*, 2012.05.02., 1.
- Jo, S. O., Lee, B. Y., SaGong, P., Chun, D. H., Park, S. W., and Cho, K. C. (2011), A Study on the Flexible Padder of High Efficiency Dyeing Machine, In *Proceedings of the Korean Society of Precision Engineering Conference*, Korean Society for Precision Engineering, 1217-1218.
- Jo, Y. J. (2018), *Big Data SPSS Latest Analysis Techniques: Neural Network, SVM, Random Forest*, Seoul Hannarae, Korea.
- Kim, J. (2019), Research Group of Polymer Frontiers, *Chemical Engineering and Materials Research Information Center*, Korea
- Korea Chemical Fibers Association (2013), *Energy Efficiency Improvement Guide*, Development of Energy Efficiency Improvement Guide for Textile Industry Research Report.
- Korea Institute of Convergence Textile (2000), *Spinning Process*, Korea Institute of Convergence Textile Industrial technology information, Korea.
- Korea Institute of Industrial Technology (1997), *Development of Dye/Preparations to Reduce Reinfiltration Rate of Dyeing Processing Factory*, Korea Institute of Industrial Technology Research Report, Korea.
- Kwn, C. M. (2006), *The Complete Guide to Python Machine Learning*, Wikibook, Korea, 183-184.
- Kwn, C. M. (2006), *The Complete Guide to Python Machine Learning*, Wikibook, Korea, 290-291.
- LeCun, Y. and Bengio, Y. (1995), *Convolutional Networks for Images, speech, and time series*, The handbook of brain theory and neural networks MIT Press, 1-14.
- Marsland, S. (2009), *Algorithm-driven machine learning guide*, 2nd,

- Chapman and Hall/CRC, London.
- Mitchell, T. M. (1997), *Machine Learning*, 1st ed., NY: McGraw-Hill Education, New York.
- Park, H. (2021), Changes in global megatrends in the textile industry and strategies to respond, *Korea Institute for Industrial Economics & Trade Report*, Korea.
- Park, K. T., Im, S. J., Noh, S. D., Kang, Y. S., and Yang, S. G. (2018), The Configuration and Utilization of Digital Twin for the Energy Efficiency Improvement of the Dyeing and Finishing Shop, *Korean Journal of Computational Design and Engineering*, **23**(4), 329-341.
- Research Group of Polymer Frontiers (2001), Polymer fiberization process, *Chemical Engineering and Materials Research Infomation Center*, Korea.
- Samuel, A. L. (1953), Some studies in machine learning using the game of checkers, *IBM Journal of Research and Development*, **3**(3), 210-229.
- Schmidhuber, J. (2015), Deep learning in neural networks: An overview, *Neural Networks*, **61**, 85-117.
- Texeye, (2016), "Spinning Process", <http://www.texeye.net/SpinningProcess-2/>, 2016.03.28.
- Yun, S. H. (2020), *Green Textile Technology and Prospects*, Korea Electronics Technology Institute PD Issue Report, Korea.

저자소개

임주희 : 성결대학교 산업경영공학과에서 2021년 학사학위를 취득하고 성균관대학교에서 산업공학과 석사과정에 재학 중이다. 연구 분야는 Cyber Physical System, Simulation Modeling Automation, Digital Twin, Data Analytics, Industrial AI이다.

양진호 : 건국대학교에서 2013년 공학사를 취득하고 성균관대학교 대학원 산업공학과 석박사 통합과정에 재학 중이다. 연구 분야는 Cyber Physical System, Digital Twin, Big Data Analytics, Reconfigurable Manufacturing System, Simulation Modeling

Automation, Smart Manufacturing이다.

조강연 : 경기대학교 산업경영공학과에서 2018년 학사학위를 취득하고 성균관대학교에서 산업공학과 석사과정에 재학 중이다. 연구 분야는 Cyber Physical System, Digital Twin, Data, Analytics, Industrial AI이다.

노상도 : KAIST 기계공학과를 졸업하고 서울대학교 기계설계학과에서 석사, 박사학위를 취득하였다. 1999년부터 2001년까지 고등기술연구원 생산기술센터에서 선임연구원으로 근무하고, 2002년부터 성균관대학교 공과대학 시스템경영공학과와 산업공학과 교수로 근무하고 있다. 연구 분야는 생산시스템 모델링 및 분석, CAD/CAPP/CAM, 디지털 가상생산/PLM, 스마트제조, 스마트공장, 사이버물리시스템(CPS)와 디지털트윈 등이다.

손현식 : 동아대학교 의상섬유학부를 졸업하고, 의상섬유학과 석사를 취득하였다. 2005년 3월부터 현재까지 DYETEC연구원 에서 근무하고 있으며, 주요 연구 분야는 섬유소재 염색 및 기능화/고성능화 가공기술, 탄소섬유 프리프레그 및 복합소재 제조 기술 등이다.

정우창 : 2015년부터 한국섬유개발연구원 ICT 및 정보화 사업 분야 시스템운영 및 사업 전담인력으로 근무하고 있다. 주요 업무 분야는 섬유산업의 빅데이터, 인공지능, 스마트제조, 디지털 전환 등 관련 실무를 담당하고 있다.

심승범 : 2003년부터 한국섬유개발연구원 산연혁신지원실 업무를 총괄하고 있다. 주요 업무 분야는 섬유분야 연구개발 및 섬유산업의 빅데이터, 인공지능, 스마트제조, 디지털 전환 등에서 공정개선, 컨설팅, 교육지원 등 업무를 총괄하고 있다.